k-means Partitioning Around Medoids (PAM)

Aprendizagem de máquina

Henrique Fan

Introdução

Estes algoritmos são usados para particionar dados em grupos, com a tentativa de minimizar as distâncias entre os pontos do grupo e um ponto que representa o centro desse conjunto.



```
x, y = readFile(k, file)
c, cx, cy = createCentroids(x, y, k)
for i in range(50):
    cx, cy = calCentroids(x, y, c, cx, cy, k)
    c = updateCluster(x, y, c, cx, cy, k)
```

```
def createCentroids(x, y, k):
    cx = []
    cy = []
    #centroide começa como algum ponto aleatório
    for i in range(k):
        cx.append(x[random.randint(0, len(x))])
        cy.append(y[random.randint(0, len(y))])
    #pontos começam em um cluster aleatório
    c = []
    for i in range(len(x)):
        c.append(random.randint(0, k-1))
    return c, cx, cy
```

```
def calCentriods(x, y, c, cx, cy, k):
    for i in range(k): #todos os clusters
        a = 0
        sumX = 0.0
        sumY = 0.0
        for j in range(len(c)): #todos os pontos
            if i = c[j]:
                sumX += x[j]
                sumY \leftarrow y[j]
                 a += 1
        print(i, a)
        if a != 0:
            cx[i] = sumX/a
            cy[i] = sumY/a
    return cx, cy
```

DISTÂNCIA EUCLIDIANA



```
x, y = readFile(k, file)
c, mx, my = createMedoids(x, y, k)
c = updateCluster(x, y, c, mx, my, k)
allowableLossCost = 10
while allowableLossCost > 0:
    for i in range(0, k):
        for j in range(0, len(c)):
               c[j] = i:
                    (mx[i] != x[j]) and <math>(my[i] != y[j]):
                     mx old = mx[i]
                     my old = my[i]
                     previousCost = calCost(x, y, c, mx, my, k)
                     mx[i] = x[j]
                     my[i] = y[j]
                     c = updateCluster(x, y, c, mx, my, k)
                     newCost = calCost(x, y, c, mx, my, k)
                     if previousCost < newCost:</pre>
                         allowableLossCost -= 1
                         mx[i] = mx old
                         my[i] = my old
                         c = updateCluster(x, y, c, mx, my, k)
```

```
def createMedoids(x, y, k):
    mx = []
    my = []
    for i in range(0, k):
        a = random.randint(0, len(x))
        mx.append(x[a])
        my.append(y[a])
    #pontos começam em um cluster aleatório
    c = []
    for i in range(0, len(x)):
        c.append(random.randint(0, k-1))
    return c, mx, my
```

```
def updateCluster(x, y, c, mx, my, k):
    for i in range(0, len(c)): #todos os pontos
        m = float('inf')
        for j in range(0, k): #todos os medoides
            distance = d(x[i], y[i], mx[j], my[j])
            if distance < m:</pre>
                m = distance
                c[i] = j
    return c
```

```
def calCost(x, y, c, mx, my, k):
    cost = 0.0
    for i in range(0, k):
        costMedoid = 0.0
        for j in range(len(c)):
            if c[j] = i:
                 costMedoid \leftarrow d(mx[i], my[i], x[j], y[j])
        cost += costMedoid
    return cost
```

DISTÂNCIA EUCLIDIANA



























